Ficha de Escopo do Projeto

Projeto Integrado em Ciência de Dados (ECD-108) — Módulo 1
PPGMCS/UNIMONTES | Prof.ª Luciana Balieiro Cosme | Setembro de 2026
Aluno: **Samuel Rodrigues Gonçalves**

---

1. Quem é afetado pelo problema?

O **operador de sala de controle** e o **analista de segurança OT** de uma planta de processo contínuo supervisionada por SCADA/DCS. O operador decide, dentro do turno, se um desvio é variação normal, falha de instrumento ou manipulação da malha de controle; o analista recebe esse indício e decide se abre investigação — decisão que concorre com a meta de disponibilidade da linha. No testbed que fornece os dados, esse sistema é uma planta de geração com turbina a vapor e bombeamento hidráulico.

2. Qual é o problema?

A detecção de manipulação no nível do controle depende hoje de **limites fixos de alarme** configurados tag a tag, herdados do projeto de automação e desenhados para falha de equipamento, não para adversário. Um ataque que altera setpoint ou comando de atuador **mantendo a variável dentro da faixa operacional** não dispara alarme: só se torna visível quando o efeito já ocorreu. Falta uma camada que observe as 86 tags **em conjunto** e sinalize a combinação anômala antes do desvio.

3. Qual o impacto do problema?

Ataque a ambiente industrial é frequente, mas quase sempre ransomware — indisponibilidade percebida no mesmo dia. O ataque tratado aqui é o que **não** se percebe, e deixou de ser hipotético: em julho de 2026 a CISA documentou campanha ativa contra PLCs Rockwell, Schneider e Siemens em água, energia e municípios, na qual a lógica maliciosa **preservava o funcionamento aparente, desabilitava o shutdown e o alarme e manipulava as telas de HMI e SCADA** [1]. O tempo médio de permanência não detectada em ambientes OT é de **42 dias**, contra 5 dias em organizações com visibilidade de processo [2] — é esse intervalo que o projeto ataca.

O custo do erro é assimétrico nos dois sentidos: falso negativo é ataque em curso; excesso de falso positivo faz o operador ignorar a ferramenta, e detector ignorado vale zero — é isso que define a métrica do item 5. Vale registrar ainda que a assinatura procurada (comando e processo deixarem de fazer sentido juntos) também aparece em instrumento descalibrado, malha esquecida em manual e desvio operacional: **a camada se paga como observabilidade de processo mesmo sem ataque algum**.

4. Que dados existem?

HAI Security Dataset 23.05 (National Security Research Institute, Coreia do Sul) — github.com/icsdataset/hai, licença CC BY-SA 4.0, download público e direto, verificado em 19/09/2026. CSV de série temporal a 1 Hz: **249 h** de operação normal (4 arquivos, 494,8 MB) e **79 h rotuladas** (2 arquivos, 284.400 registros, 156,6 MB) contendo **52 ataques**, período de 12 a 19/08/2022. São **86 tags** de sensores e atuadores, sem valores ausentes. Prevalência da classe positiva: **4,00%**. Detalhamento no anexo (Entrega 1).

5. Como o sucesso será medido?

A acurácia é inutilizável: responder sempre “normal” rende **96,00%** sem detectar nenhum ataque. A avaliação é por **evento**, não por segundo.

Técnica (primária)	**Cobertura de eventos sob orçamento de alarme** — proporção dos 52 ataques com ao menos um segundo corretamente sinalizado, sob a restrição de **no máximo 1 alarme falso por hora** de operação normal. Meta: **≥ 70%**.
Técnica (apoio)	**Latência mediana de detecção** (meta ≤ 60 s, abaixo da mediana de duração dos ataques, que é 132 s) e **PR-AUC** por ponto, adequada à prevalência de 4%.
Negócio	**Alarmes falsos por turno de 8 horas** — grandeza que o supervisor de operação efetivamente negocia: o teto de 1/hora equivale a 8 interrupções por turno.

6. Qual é a hipótese?

> **Acredito que estatísticas móveis (média, desvio-padrão e delta) das 86 tags em janelas de 30 a 120 segundos detectam ao menos 70% dos 52 ataques respeitando o teto de 1 alarme falso por hora, porque os ataques manipulam comando e setpoint sem que o conjunto das variáveis de processo acompanhe de forma fisicamente coerente — e essa incoerência é multivariada, não observável em nenhuma tag isolada.**

A versão univariada dessa ideia já foi testada e **descartada**: o resíduo entre comando e realimentação dos 6 pares D/Z do subsistema 1, calibrado no percentil 99 da operação normal (exatamente 1% de alarme falso), detecta **1 dos 14 ataques** de hai-test1 — fica registrado como **baseline a ser superado**. O resultado é coerente com a documentação do dataset, que descreve os ataques da versão 22.04 em diante como cerca de quatro vezes mais difíceis de detectar que os da 21.03.

> **Quero classificar se uma janela de operação do processo está sob ataque usando as 86 tags de sensores e atuadores do HAI 23.05 para que o operador de sala de controle e o analista de segurança OT possam abrir investigação antes que a variável saia de faixa, sem serem soterrados por alarme falso.**

Referências do item 3

[1] CISA. *Iranian-Affiliated Cyber Actors Exploit PLCs Across US Critical Infrastructure*, alerta AA26-097A, jul. 2026.
[2] DRAGOS. *OT Cybersecurity Year in Review 2026* (dados de 2025). Acessos em 20/09/2026.

Anexo — Exploração mínima (Entrega 1 do Módulo 1)

Apuração feita pelo autor sobre os arquivos baixados em 19/09/2026.

Fonte e link	HAI Security Dataset 23.05 — github.com/icsdataset/hai — CC BY-SA 4.0, acesso público e direto, sem cadastro. Ref.: Shin et al., HAI 1.0: HIL-based Augmented ICS Security Dataset, USENIX CSET 2020.
Registros	Normal: 4 CSV, 249 h, 494,8 MB. Rotulados: 2 CSV, 79 h = **284.400 registros** a 1 Hz, 156,6 MB, **52 ataques** — hai-test1 (54.000 linhas, 12–13/08/2022, 14 ataques, 5,52%) e hai-test2 (230.400 linhas, 17–19/08/2022, 38 ataques, 3,65%).
Colunas	**86 tags** + timestamp. Por subsistema: P1 = 37, P2 = 24, P4 = 11, P3 = 7, mais 7 setpoints do simulador HIL. Rótulos em arquivo separado (label-test*.csv).
Qualidade	Nenhum valor ausente. **27 das 86 tags são constantes** em hai-test1 — candidatas a remoção. Continuidade temporal preservada, sem lacunas de timestamp.
Classe alvo	Binária (label). Prevalência global **4,00%**. Duração dos ataques: mín. 56 s · mediana 132 s · máx. 2.052 s; **17 dos 52 duram menos de 2 minutos**.

Três variáveis principais

P1_LIT01	Transmissor indicador de nível do subsistema 1 — variável de processo afetada por manipulação de vazão a montante.
P1_PIT01	Transmissor indicador de pressão; possui tag companheira de alarme (P1_PIT01_HH), o que permite comparar o detector com o alarme convencional existente.
P1_FCV01D / 01Z	Par comando/realimentação de válvula de controle de vazão (D = demanda, Z = posição realimentada). São 6 pares D/Z; base do baseline do item 6.

A leitura dos sufixos segue a convenção ISA-5.1 e será confirmada contra o manual técnico do dataset no Módulo 2.

Limitações identificadas

(i) Os arquivos de treino contêm apenas operação normal — o dataset foi concebido para detecção não supervisionada; o uso supervisionado exige recorte cronológico dos arquivos rotulados, e validação cruzada aleatória fica excluída do pipeline. **(ii)** São 52 ataques no total: a avaliação por evento tem amostra pequena e os resultados serão reportados como distribuição, não como número único. **(iii)** A partir da versão 22.04 os rótulos por subprocesso foram removidos — por isso o escopo se limita à detecção, sem localização do alvo. **(iv)** São dados de testbed: o modelo não é transferível para outra instalação sem recalibração, limitação que será declarada de forma visível no dashboard.

Declaração de uso de Inteligência Artificial

Declaro que utilizei a ferramenta de Inteligência Artificial **Claude (Anthropic), modelo Opus 5**, em setembro de 2026, como apoio na elaboração deste trabalho: levantamento de fontes de dados candidatas, execução de rotinas de exploração sobre os arquivos do dataset e revisão da redação. Afirmo que li, revisei e adaptei todo o conteúdo, mantendo responsabilidade integral sobre o material apresentado. Não foram produzidos por IA: a escolha do domínio e do problema, a definição do recorte, as metas das métricas e as decisões de escopo. O diário de prompts é mantido em prompts_log.md no repositório.